모바일 환경에서의 큐싱(Qshing) 공격 방지를 위한 실시간 머신러닝 기반 탐지 시스템 구현

이시언[1†], 오나희[2], 이지원[2], 김기성[3‡]

[1,2,3]대구가톨릭대학교 (학생, 교수)

Implementation of a Real-time ML-based Detection System to Prevent Qshing Attacks on Mobile Devices

Si-Eon Lee[1†], Na-Hee Oh[2], Ji-Won Lee[2], Kee-Sung Kim[3‡]

[1,2,3]Daegu Catholic University (Undergraduate student, Professor)

요 약

본 연구는 QR코드를 악용한 큐싱(Qshing) 공격을 탐지하기 위해, URL의 정적 특성을 활용한 머신러닝 기반 분류 모델을 제안한다. 약 100만 건의 데이터를 청크 단위로 분할해 학습하고, PyCaret 기반 AutoML을 통해 최적 알고리즘(Logistic Regression)을 선정하였다. 청크별 모델을 앙상블하여 일반화 성능을 향상시켰으며, Android 애플리케이션과 연동하여 실시간 탐지 시스템을 구현하였다. 본 시스템은 사용자 편의를 유지하면서 큐싱 피해를 효과적으로 예방할 수 있다.

I. 서론

1.1 연구 배경

코로나19 팬데믹 이후 비대면 서비스 확산과 함께 QR코드는 식당 주문, 출입 인증, 결제, 광고 등 다양한 분야에서 간편한 정보 접근 수단으로 널리 활용되고 있다. 그러나 QR코드가 다양한 분야에 사용되면서, 동시에 보안 위협도 증가하고 있다. 특히 '큐싱(Qshing)'은 악성 웹사이트 유도나 앱 설치를 통해 개인정보를 탈취하는 방식으로, 정상 QR코드와 외형상 구분이 어려워 사용자에게 큰 위협이 된다.

1.2 연구 목적

본 연구는 악성 QR코드에 포함된 URL의 정적 특성을 기반으로 큐싱 여부를 분류할 수 있는 기계학습 기반 탐지 모델을 개발하고, 이를 모바일 애플리케이션과 연동하여 사용자 편의를 유지하면서도 실시간 보안이 가능한 QR코드 사용 환경을 구현하는 것을 목표로 한다.

II. 선행 연구

초기 큐싱 대응 연구는 블랙리스트 기반 탐지 방식에 집중되었다. 이는 QR코드로 연결되는 URL을 사전에 수집된 악성 URL 목록과 비교해 차단하는 방식으로, 주로 모바일 스캐너 애플리케이션과 연동되어 경고 메시지를 제공하는 구조였다. 구현이 간단하고 이미 알려진 위협에 효과적이라는 장점이 있지만, 새로운 유형의 악성 URL이나 변종 공격에는 탐지력이 떨어지고 실시간 대응이 어렵다는 한계를 지닌다.

이러한 한계를 극복하기 위해 최근에는 머신러닝 및 딥러닝 기반 탐지 기법이 활발히 연구되고 있다. URL의 길이, 특수문자 수, 도메인

† 주저자, sieon0712@cu.ac.kr

‡ 교신저자, kee21@cu.ac.kr (Corresponding author)

구조 등 정적 특성을 기반으로 악성 여부를 분류하는 방식이며, 지능적인 패턴 인식을 통해 탐지 성능을 향상시키고자 한다. 그러나 기존 연구는 주로 웹 기반 시스템에 한정되어 있고, 비교한 모델 수가 제한적이며, 정상 URL 비중이 과도하게 높은 비대칭적 데이터셋을 사용하여 현실 적용에 제약이 있다.

본 연구는 이러한 한계를 보완하고자 모바일 애플리케이션에 실시간 탐지 모델을 연동하고, 총 16개의 머신러닝 모델을 비교 분석하였다. 또한 AutoML 기반 모델 탐색과 분산 학습 전략을 도입하여 대규모 데이터를 효율적으로 처리하였으며, 실제 공격 환경을 반영한 악성 URL 중심의 데이터셋을 구성하여 실질적인 탐지 성능을 입증함으로써 기존 연구와 차별성을 가진다.

III. 시스템 설계

3.1 데이터 수집 및 전처리

본 논문에서는 Kaggle, KISA, URLhaus, PhishTank 등 신뢰성 있는 공개 플랫폼에서 정상 및 악성 URL 데이터를 수집하였으며, 이를 중복 제거, 결측치 보완, 문자열 정규화 등의 전처리 과정을 통해 학습에 적합한 형태로 정제하였다. 주요 피처는 URL 문자열과 악성 여부 외에도 IP 주소 포함 여부, 비정상적인 길이, 단축 URL 사용 여부 등 구조적 특징을 반영하여, 행위 분석 없이도 효과적인 정적 분석 기반 예측이 가능하도록 설계되었다.

3.2 모델 설계 및 학습

모델 학습은 PyCaret 기반의 AutoML 프레임워크를 활용하여 수행되었으며, Logistic Regression, Random Forest, LightGBM, XGBoost, SVM 등 총 14개의 알고리즘을 대상으로 성능을 비교하였다. 전체 약 100만 건의 데이터를 메모리 효율을 고려해 25만 건 단위의 4개 청크로 분할하고, 각 청크마다 최적 모델을 선택하여 학습하였다.

이후 각 청크별 최적 모델들을 앙상블 방식으로 결합하여 하나의 완성된 예측 모델을 구성하였다. 이와 같은 청크 기반 분산 학습과 앙상블 기법은 대용량 데이터 처리 효율을 향상시킴과 동시에 모델의 일반화 성능 향상에 기여하였다.

3.3 모바일 애플리케이션 연동

최종 학습된 예측 모델은 Android Studio 기반의 모바일 애플리케이션에 통합되었다. 사용자가 QR 코드를 스캔하면 앱이 URL을 자동 추출하고, 이를 백엔드 서버에 전달하여 실시간으로 악성 여부를 판별한다. 분석 결과는 경고 메시지 형태로 사용자에게 시각적으로 제공하여 큐싱 피해를 예방할 수 있도록 설계되었다.

IV. 실험 및 결과 분석

4.1 청크 기반 최적 모델 선정

전체 데이터는 약 100만 건 규모로, 이를 25만 건씩 4개의 청크로 나누어 개별적으로 학습 및 평가를 수행하였다. 각 청크별로 PyCaret 기반의 AutoML을 활용해 다양한 알고리즘을 실험한 결과, Logistic Regression이 모든 청크에서 가장 안정적이고 높은 성능을 기록하여 최종 후보 모델로 선정되었다. 청크별 성능은 다음과 같다.

[표1] 분할한 청크 별 학습한 모델 성능

Chunk Range	Model	Accuracy	Recall	Precision	F1 Score
0 ~ 249,999	Logistic Regression	0.9603	0.9405	0.9812	0.9600
250,000 ~ 499,999	Logistic Regression	0.9743	0.9505	0.9915	0.9698
500,000 ~ 749,999	Logistic Regression	0.9534	0.9404	0.9690	0.9546
750,000 ~ 999,999	Logistic Regression	0.9683	0.9436	0.9818	0.9614

모든 청크에서 높은 정확도와 정밀도를 유지하였으며, 재현율도 평균적으로 안정적인 수치를 기록하였다. 이는 모델이 악성 URL을 민감하게 탐지하면서도 오탐률을 낮게 유지했음을

보여준다. 특히 두 번째 청크의 모델이 가장 높은 F1 Score를 기록하였다.

최종 통합 모델은 데이터를 4개의 청크로 나누어 각각 모델을 학습한 뒤, 각 청크에서 가장 성능이 좋은 모델을 하나씩 선정해 앙상블하여 구성하였다.

[표2] 최종 모델 성능

Accuracy	Recall	Precision	F1 Score
0.9663	0.945	0.980	0.961

이 결과는 일부 개별 모델보다 다소 낮을 수 있으나, 전체 지표가 고르게 유지되며 성능 편차를 줄이고 일반화 가능성을 높인 점에서 의미가 있다. 단일 모델의 편차를 완화하고, 실시간 서비스 환경에서 보다 안정적인 탐지 성능을 제공할 수 있도록 설계되었다.

4.2 앙상블 기반 통합

전체 데이터셋을 청크 단위로 분할하고, 각 청크에서 가장 우수한 모델을 추출하여 이를 앙상블 방식으로 통합하였다. 이 방식은 일부 청크에서 발생할 수 있는 데이터 편향을 완화하고, 전반적인 성능의 일관성과 안정성을 확보하는 데 목적이 있었다.

최종 모델의 성능은 일부 개별 청크 모델과 비교해 비슷한 수준이지만, 전체적으로 균형 잡힌 정확도를 유지하였다. 이는 모델 통합이 극적인 성능 향상을 이끌어내지는 않았지만, 실시간 서비스 환경에서의 일반화 성능과 신뢰도를 확보하는 데 유효한 전략이었음을 보여준다.

V. 결론 및 향후 연구

본 연구는 QR코드를 악용한 큐싱 공격으로부터 사용자를 보호하기 위해, URL의 정적 특성을 기반으로 한 머신러닝 탐지 시스템을 설계하였다. 대용량 데이터를 청크 단위로 처리하고, AutoML을 통해 최적 모델을 효율적으로 탐색하였으며, 각 청크에서 도출된 모델을 앙상블함으로써 정확도와 일반화 성능을 동시에 확보하였다. 특히 모바일 애플리케이션과의 연동을 통해 사용자가 QR코드를 스캔하는 즉시 URL의 위험 여부를 실시간으로 판단하고 시각적 경고를 제공함으로써, 사용자 편의를 해치지 않으면서도 효과적인 보안 대응 방안을 제시하였다.

향후 연구에서는 QR코드를 스캔할 때 사용자가 특정 앱을 별도로 실행하지 않아도, 기본 카메라 앱을 통해 본 시스템의 탐지 기능을 사용할 수 있도록 기능 확장을 계획하고 있다. 이를 위해 Android 카메라 프리뷰 데이터를 가로채는 방식의 CameraHook 기술을 적용할 예정이다. CameraHook은 onPreviewFrame(byte[] data, Camera camera) 콜백을 활용하여 외부 애플리케이션을 통해 인식된 QR코드에 대해서도 본 시스템의 탐지 기능이 작동할 수 있도록 한다. 해당 기능은 루팅 환경에서만 가능하다는 제약이 있으나, 향후 루트 권한 없이도 작동 가능한 보안 프레임워크로 발전시키는 것을 목표로 하고 있다.

[참고문헌]

[1] 이동건, 황규준, 김동오, 황진석, 큐싱(Qshing) 해킹 대응 방안 연구, 한국IT정책경영학회 학술지, 제16권 제1호, 통권 29호, 2024, pp. 37-49.

[2] 신현창, 이주형, 김종민, 큐싱(Qshing) 공격 탐지를 위한 시스템 구현, 융합보안논문지, 제23권 제1호, 2023, pp.55-61

[3] 김동영, 황기성, 큐싱 공격 탐지를 위한 AutoML 머신러닝 기반 악성 URI 분류 기술 연구 및 서비스 구현, 스마트미디어저널, 제13권 제6호, 2024년 6월. https://dx.doi.org/10.30693/SMJ.2024.13.6.9

[4] 이종호, 신용태, CV 기반 악성 URL 탐지 앙상블 스태킹 모델, ASK 2024 학술발표대회 논문집, 제31권 제1호, 2024.